

INFORME DE CIENCIA DE DATOS

De señales y redes a decisiones operativas

Auditoría, integración y analítica multidimensional para TechLogistics S.A.

Decisión central. Proteger el nodo energético 119 y desplegar intervenciones hídricas puntuales por sensor; la evidencia no respalda una intervención territorial por pendiente ni incorporar centralidad al pronóstico de demanda.

Organización: TechLogistics S.A. (caso académico)

Autor(a): Cristian Gómez Salazar y Santiago Vélez Casallas

Curso: Análisis de Datos Avanzado / Fundamentos en Ciencia de Datos

Docente: Jorge Iván Padilla-Buriticá

Institución: Universidad EAFIT

Periodo: 2026-2

Fecha: 08 de Agosto

Resumen ejecutivo

Este informe traduce el análisis del notebook “challenge03_analitica_multidimensional” a decisiones para administradores. Se analizaron 2.000 registros de las redes agro y energía mediante estadística espacial, series de tiempo, procesamiento de señales, grafos y pronóstico. Los resultados fueron reproducidos al ejecutar el notebook completo; las figuras y cifras se originan allí.

Tabla 1. Hallazgos y decisiones prioritarias.

Hallazgo	Evidencia	Decisión
Nodo energético crítico	Nodo 119: 120 registros; betweenness=0 en toda la red	Redundancia y compensación reactiva en nodo 119
Factor de potencia anticipa voltaje	Granger $p=0,019$; rezago 4 h; dirección inversa $p=0,113$	Alerta temprana sobre factor de potencia
NDVI sin patrón territorial	Moran $I \approx 0$; Spearman $\rho=0,010$, $p=0,828$	Intervenir sensores puntuales, no “zonas de pendiente”
Pronóstico de demanda	RMSE 2,69 vs 2,68; mejora 0,4%; DM $p=0,44$	Mantener temperatura; no añadir centralidad
Filtrado de humedad relativa	RMSE 3,341→1,307; reducción 60,9%	Filtrar antes de modelar y alertar
Costo del gas con tendencia	Pendiente 0,011; $R^2=0,978$; $p \approx 0$	Modelar diferencias y monitorear tendencia

Advertencia de evidencia. La llamada “falla del nodo 214” no aparece en los datos: recibe 27 registros, incluso uno con precio superior al percentil 90; sus medias de precio y temperatura son similares a las globales. Se trata como marco narrativo, no como anomalía demostrada.

1. Alcance, datos y método

El reto exige: (T1) geovisualización; (T2) estacionariedad y ventanas móviles; (T3) FFT y densidad espectral; (T4) filtrado Butterworth; (T5) red dirigida y centralidades; y respuestas P1–P3. El checklist añade cuatro preguntas de validación. Este informe cubre los diez componentes y remite al notebook como registro reproducible del procedimiento.

Tabla 2. Fuentes y trazabilidad del informe.

Fuente	Uso
Lecture_03_Challenge.pdf	Enunciado, tareas T1–T5 y preguntas P1–P3.
Lecture_03_checklist.pdf	Activos exigidos, validaciones y rúbrica.
Lecture_03_dictionary.pdf	Significado de variables, naturaleza temporal y ruido.
challenge03_analitica_multidimensional(1).ipynb	Código, textos Markdown, tablas, métricas y figuras reproducidas.
Este informe	Síntesis ejecutiva; se autorreferencia mediante Tablas 1–10 y Figuras 1–8.

Supuestos: los archivos clean existen y se usan como referencia para SNR/RMSE; los CSV no contienen fecha y se adopta un índice horario sintético desde 2023-01-01; semilla 42; significancia estadística $\alpha=0,05$. Estos supuestos están declarados en el notebook.

2. Diagnóstico técnico explicado para negocio

2.1 Geografía: la biomasa baja no forma una zona continua

En la Figura 1, el color representa NDVI (verdor o biomasa) y el tamaño representa humedad. Los valores bajos aparecen dispersos. La prueba de Moran confirma que la cercanía geográfica no produce valores de NDVI parecidos: $I=0,0148$ con 8 vecinos ($p=0,153$) e $I=0,0019$ con 15 vecinos ($p=0,750$). Ambos resultados son compatibles con aleatoriedad espacial.




Figura 1. Sensores agro en el Oriente antioqueño: color=NDVI y tamaño=humedad. Fuente: elaboración propia a partir del notebook, T1.

2.2 Series de tiempo: qué cambia y qué permanece estable

Tabla 3. Resultado ADF de estacionariedad ($\alpha=0,05$).

Grupo	Variables	Lectura
No estacionarias	Ener_1, Ener_2, Ener_3, Ener_5, Ener_6, Ener_7	Media o nivel cambia; diferenciar antes de ARIMA/correlación.
Estacionarias	Ener_4, Ener_8, Ener_9, Ener_10	Fluctúan alrededor de un nivel estable; aptas para análisis en nivel.

El costo del gas (Ener_5) sube aproximadamente de 5 a 25. La pendiente estimada es 0,01109 por hora, con $R^2=0,978$ y $p\approx 0$; el cambio medio por paso también es significativo ($p=3,31\times 10^{-6}$). Por ello se clasifica como caminata aleatoria con deriva, no como fluctuación sin dirección (véase Figura 2).




Figura 2. Costo del gas: serie, media móvil y varianza móvil de 50 registros. La media ascendente evidencia deriva. Fuente: notebook, T2.

2.3 Señales: dónde está el ruido y cuánto ayuda filtrarlo

La generación eólica (Ener_4) conserva su señal en frecuencias bajas, mientras el ruido eleva de forma casi uniforme las frecuencias altas. El 81,5% de la energía del residuo está por encima de 0,1 ciclos/hora y el pico del ruido aparece cerca de 0,293 ciclos/hora. El SNR observado es 18,0 dB, mayor que el rango nominal del enunciado (5–12 dB), pero Ener_4 sigue siendo la serie energética más ruidosa del grupo principal.




Figura 3. FFT y PSD de Ener_4: la versión con ruido eleva la energía en frecuencias altas. Fuente: notebook, T3.

Aplicar un Butterworth pasa-bajo de orden 4 a Agro_3 reduce el RMSE frente a la señal limpia de 3,3414 a 1,3071: una mejora de 60,3%. En términos gerenciales, el filtro elimina oscilaciones rápidas que inducirían falsas alertas y sobreajuste (Figura 4).




Figura 4. Humedad relativa: señal ruidosa, referencia limpia y reconstrucción Butterworth. Fuente: notebook, T4.

2.4 Red: el cuello de botella real es el nodo 119

Los nodos de origen y destino son conjuntos separados y solo existe un salto. Por eso ningún nodo actúa como intermediario y la betweenness vale 0 para todos. La criticidad debe medirse por throughput: cantidad de registros que circulan por el nodo. El nodo 119 lidera energía (120 registros) y el 10 lidera agro (172).




Figura 5. Redes dirigidas bipartitas. En rojo se destaca el nodo de mayor throughput: Agro 10 y Energía 119. Fuente: notebook, T5.

Tabla 4. Nodos críticos por tráfico observado.

Red	Nodo	Throughput	Betweenness	Criterio
Agro	10	172	0,000	Mayor tráfico
Energía	119	120	0,000	Mayor tráfico

3. Preguntas de negocio y recomendaciones

P1. ¿El factor de potencia anticipa el voltaje y qué implica para la red?

El test de Granger evalúa si el pasado del factor de potencia aporta información para anticipar el voltaje, además del propio historial del voltaje. Ambas series son estacionarias, por lo que el contraste se aplica en nivel. Se probaron ocho rezagos y ambas direcciones.

Tabla 5. Resultado direccional del test de Granger.

Dirección	Mejor resultado	Conclusión
Factor de potencia → Voltaje	$p=0,019$; rezago 4 h	Sí anticipa
Voltaje → Factor de potencia	$p=0,113$	No anticipa




Figura 6. P-values de Granger por rezago. Solo la dirección azul cruza el umbral 0,05. Fuente: notebook, P1.

Respuesta P1. Existe causalidad direccional: el factor de potencia anticipa el voltaje unas 4 horas y no al revés. Si una falla en el nodo 119 degrada el factor de potencia, la inestabilidad puede aparecer después en los destinos que alimenta; no necesariamente en los destinos de otras fuentes. Se recomienda compensación reactiva, monitoreo preventivo y redundancia física en el nodo 119.

P2. ¿Debe priorizarse infraestructura hídrica en zonas de pendiente?

Se filtró el jitter GPS agregando los registros en 468 celdas aproximadas de 1 km y se comparó el NDVI medio con Agro_10, usado en el enunciado como proxy de pendiente. El resultado de Spearman es $p=+0,010$ y $p=0,828$: la nube no muestra patrón y el efecto no es estadísticamente significativo (Figura 7). Además, el diccionario define Agro_10 como señal estacionaria/ruido blanco, de modo que es un proxy débil para pendiente.




Figura 7. NDVI frente al proxy de pendiente en 468 celdas GPS. La dispersión sin tendencia respalda $p \approx 0$. Fuente: notebook, P2.

Respuesta P2. Los datos no justifican concentrar la inversión “por zonas de pendiente”. La biomasa baja es local y no forma clústeres geográficos. Se recomienda una intervención escalonada por sensor: auditar humedad y suelo en los puntos de bajo NDVI, ejecutar pilotos de riego localizado y ampliar solo donde exista mejora medida. Para una decisión territorial futura, se requiere un modelo digital de elevación o medición real de pendiente.

P3. ¿La centralidad mejora el pronóstico de demanda?

Se entrenó un ARIMAX con la primera mitad de la serie y se pronosticó la segunda, no vista. El modelo base usa temperatura; el segundo añade centralidad de grado del nodo de origen. La comparación fuera de muestra es casi idéntica.

Tabla 6. Comparación de pronóstico fuera de muestra.

Modelo	RMSE	Lectura
Temperatura	2,69	Base
Temperatura + centralidad	2,68	Mejora de solo 0,4%
Variación natural de demanda	14,38	Ambos errores son bajos




Figura 8. Demanda real y pronósticos. Las curvas azul y roja prácticamente se superponen. Fuente: notebook, P3.

Respuesta P3. La centralidad no mejora de forma útil el pronóstico: el RMSE cambia 0,4% y la prueba de Diebold-Mariano da $p=0,44$. Para esta muestra, la temperatura ya captura la señal predictiva. Se recomienda mantener el modelo simple y reservar la centralidad para análisis de riesgo y continuidad, donde sí aporta valor.

4. Preguntas de validación

4.1 ¿Por qué no usar Pearson directamente sobre una serie con tendencia?

Pearson puede confundir una tendencia con una relación real: Ener_5 y Ener_6 dan un Pearson fortísimo ($r = -0.99$), pero es espurio — nace solo de sus tendencias opuestas, no de que una influya en la otra. Al analizar las diferencias (sin tendencia), la correlación se desploma a 0.02 (Figura 9.Q1). El engaño no es el signo, sino la magnitud

4.2 ¿Qué impacto tiene ruido de 5 dB en un ARMA frente a clean?

El ruido subestima la persistencia de la serie: sesga los coeficientes ARMA hacia 0. En una serie con memoria real 0.7, con ruido de 5 dB se mide solo 0.54 (Figura 9.Q2). Por eso un modelo ajustado sobre datos ruidosos "cree" que la serie tiene menos inercia de la que tiene — y por eso filtrar el ruido antes de modelar (T4) recupera los coeficientes verdaderos.

4.3 ¿Cómo cambia una falla si el sensor es un bridge?

En una red multisalto, un bridge conecta subredes: su caída no solo elimina una medición, sino que fragmenta la conectividad y corta telemetría o despacho. En este dataset no hay bridges porque la red es bipartita de un salto; la criticidad práctica recae en el nodo de mayor throughput, 119 en energía.

4.4 ¿Cómo influye la posición geográfica en la varianza capturada?

En teoría, ladera, viento, escorrentía y microclima pueden modificar la varianza. En estos datos no se observa estructura espacial: Moran $I \approx 0$ y NDVI no se relaciona con el proxy de pendiente ($\rho \approx 0$). Por tanto, la geografía podría influir en otro estudio, pero aquí no explica la variación observada.




Figura 9. Gráficas que soportan las respuestas a las preguntas de validación.

5. Plan de acción recomendado

Tabla 7. Acciones, responsables sugeridos e indicadores.

Horizonte	Acción	Indicador
0–30 días	Instrumentar factor de potencia y voltaje en nodo 119; definir alarmas con ventana de 4 h.	Cobertura de telemetría; alertas validadas
0–60 días	Diseñar redundancia y evaluar bancos de capacitores en nodo 119.	Rutas alternativas; estabilidad de voltaje
0–45 días	Aplicar filtrado Butterworth en Agro_3 antes de modelos y alertas.	RMSE y falsas alertas
30–90 días	Pilotos hídricos en sensores de bajo NDVI, sin zonificación por pendiente.	Cambio NDVI/humedad vs control
Trimestral	Reentrenar pronóstico con temperatura; aceptar nueva variable solo con mejora fuera de muestra.	RMSE y prueba DM

6. Limitaciones y trazabilidad

El tiempo es sintético; el dataset es académico; Agro_10 no mide pendiente; la topología observada es bipartita aunque el diccionario usa la palabra mesh; y el SNR realizado de Ener_4 (18 dB) no coincide con el rango nominal del reto. Estas limitaciones restringen generalizaciones y se informan para evitar recomendaciones más fuertes que la evidencia.

Referencias internas: las conclusiones P1, P2 y P3 se sustentan en las Tablas 5–6 y Figuras 6–8; la recomendación hídrica también usa Figura 1; el riesgo de red usa Tabla 4 y Figura 5. El notebook contiene el código, los textos Markdown, las salidas numéricas y las figuras reproducidas en este informe.

Referencias

1. Universidad EAFIT (2026). Lecture_03_Challenge.pdf. Workshop: Inteligencia Geo-Temporal y de Redes.
2. Universidad EAFIT (2026). Lecture_03_checklist.pdf. Checklist de Entrega y Evaluación.
3. Universidad EAFIT (2026). Lecture_03_dictionary.pdf. Manual de Diccionario de Datos v2.0.
4. Gómez Vélez et al. (2026). challenge03_analitica_multidimensional(1).ipynb. Notebook de análisis reproducible.
5. TechLogistics S.A. (2026). Informe de ciencia de datos: de señales y redes a decisiones operativas. Este documento.
6. International Organization for Standardization. (2015). Data quality — Part 8: Information and data quality: Concepts and measuring (ISO Standard No. 8000-8:2015). <https://www.iso.org/standard/60805.html>
7. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.
8. Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference, 92–96. <https://doi.org/10.25080/Majora-92bf1922-011>
9. Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424–438. <https://doi.org/10.2307/1912791>
10. Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>