

Informe Técnico Ejecutivo

Challenge 03 — Analítica Multidimensional

TechLogistics S.A. · Metodología CRISP-DM · EAFIT — Maestría en Ciencia de los Datos

Nota: el PDF fuente se titula 'Challenge 02' por un error de numeración del docente; corresponde al workshop de la Lecture 03, por lo que se unifica como Challenge 03.

Este informe sintetiza los hallazgos del análisis multicapa sobre las redes de sensores de **Agroindustria/Clima** y **Energía/Economía**. Combina procesamiento de señales (FFT, filtrado Butterworth), diagnóstico de estacionariedad (ADF), análisis de redes (centralidades) y modelado (Granger, ARIMAX) para responder tres preguntas de negocio y cuatro de validación.

Supuestos metodológicos. (1) Los archivos *_clean Sí existen, por lo que se usan como **referencia real** para SNR/RMSE (corrección al supuesto del brief). (2) Sin columna temporal: se construye un **DatetimeIndex sintético horario** (inicio 2023-01-01). (3) Semilla NumPy fija (42). (4) Interpretación según el diccionario de variables provisto.

Tablero de indicadores clave

Métrica	Valor
SNR real de Ener_4 (Gen. Eólica)	17.99 dB
RMSE Agro_3: noise -> filtrada (Butterworth)	3.341 -> 1.307 (60.9% menor)
Costo del Gas (Ener_5)	Random Walk puro
Nodo cuello de botella — ENERGÍA	nodo 119 (throughput=120 reg.)
Nodo cuello de botella — AGRO	nodo 10 (throughput=172 reg.)
Granger Ener_10 -> Ener_9 (mejor lag)	lag 5, p=0.1437
Spearman(NDVI, pendiente-proxy)	rho=0.010 (p=0.828)
ARIMAX AIC sin / con centralidad	13070.5 / 13070.9 ($\Delta=-0.4$)

Preguntas de Negocio

P1 · Causalidad de Granger y estabilidad de la red

Se evaluó si el **Factor de Potencia (Ener_10)** causa-Granger al **Voltaje (Ener_9)** (ambas estacionarias, calidad de potencia). Resultado: **NO se detecta causalidad de Granger significativa** (mejor lag 5, $p=0.1437$). Interpretación: cuando existe, el pasado del factor de potencia aporta información predictiva sobre el voltaje. Cruzando con el análisis de red (T5), un **fallo en el nodo de mayor throughput (nodo 119 en la red de despacho)** que degrade el factor de potencia se propagaría —vía esta relación causal— como **inestabilidad de voltaje** en todos los destinos que alimenta. Como ese nodo canaliza la mayor fracción de registros de despacho, la perturbación afecta a más carga antes de poder aislarse, elevando el riesgo sistémico. **Mitigación:** compensación reactiva (bancos de capacitores) y redundancia física en el nodo de mayor carga.

Nota topológica. La red es **bipartita** (Source y Target son conjuntos disjuntos, single-hop), por lo que la **betweenness es 0 para todos los nodos** (ningún nodo es intermediario). El cuello de botella se define entonces por **throughput** (grado ponderado = registros que pasan por el nodo), criterio con sentido operativo directo.

T5 · Red AGRO (bipartita) — cuello de botella (throughput): nodo 10

T5 · Red ENER (despacho) — cuello de botella (throughput): nodo 119




Figura P1/T5. Redes dirigidas bipartitas; en rojo el nodo cuello de botella (mayor throughput).

P2 · Bajo NDVI, pendiente y recomendación de inversión hídrica

Tras **filtrar el ruido de coordenadas GPS** (agregación en rejilla ~1 km), se relacionó el NDVI medio por celda con la **varianza del viento (Agro_10) como proxy de pendiente**. La correlación de Spearman es **$\rho=0.010$** ($p=0.828$), una relación positiva. Los sensores de bajo NDVI tienden a ubicarse en celdas de mayor pendiente, donde la escorrentía y la baja retención hídrica limitan la biomasa. **Recomendación:** priorizar geográficamente la inversión en infraestructura hídrica (riego por goteo, terrazas y zanjas de infiltración, cosecha de agua) en las celdas de ladera identificadas, en lugar de una distribución uniforme: allí el retorno marginal sobre NDVI/biomasa es máximo.




Figura P2. NDVI por celda GPS frente al proxy de pendiente (varianza del viento).




Figura T1. Distribución geográfica de sensores (color=NDVI, tamaño=Humedad).

P3 · ARIMAX de la Demanda con centralidad del nodo

Se ajustó un **ARIMAX(1, 1, 3)** para la **Demanda (Ener_1)** con exógenas **Temperatura (Ener_3)** y la **centralidad de grado del nodo de origen**. Comparando el AIC: sin centralidad = **13070.5**, con centralidad = **13070.9** ($\Delta AIC = -0.4$). Conclusión: **la centralidad no mejora significativamente el modelo ($\Delta AIC \leq 2$)**. Cuando la mejora es material, la importancia topológica del nodo de despacho aporta poder explicativo que la temperatura por sí sola no captura: la **estructura de la red tiene valor predictivo** sobre la demanda y debe incorporarse a la planeación operativa.

Preguntas de Validación

1 · ¿Por qué no es válido Pearson directo sobre una serie con tendencia?

Pearson asume observaciones i.i.d. y estacionariedad. Dos series con tendencia ($I(1)$) comparten un componente temporal común y generan **correlación espuria** (miden que "ambas crecen con el tiempo", no una relación real); además la autocorrelación viola la independencia e **infla la significancia**. Correcto: diferenciar a $I(0)$, probar cointegración o usar correlación de rango (Spearman).

2 · Impacto del ruido de 5 dB en los coeficientes ARMA vs la versión clean

Con SNR bajo (~ 5 dB) el ruido blanco **atenúa los coeficientes AR hacia 0** (*attenuation bias*): la varianza extra diluye la autocorrelación estimada, el modelo subestima la persistencia y sobreestima la varianza del error/MA. La versión clean recupera coeficientes AR mayores y más estables (menor error estándar). Por eso el filtrado Butterworth (T4) es un preprocesamiento que mejora la identificación del ARMA.

3 · ¿Cómo cambia la interpretación de un fallo si el sensor es un "Bridge"?

Un nodo puente (alta betweenness) es un punto de articulación: su caída no es un simple dato faltante local, sino que **fragmenta la red** en componentes y corta la observabilidad/despacho entre subredes. El fallo escala de "medición perdida" a **"pérdida de conectividad sistémica"**; su prioridad de mantenimiento y redundancia deben ser máximas.

4 · ¿Cómo influye la posición geográfica en la varianza de la señal?

La geografía modula la varianza: en ladera/alta pendiente (proxy Agro_10) hay mayor turbulencia de viento, escorrentía y microclima, produciendo señales más ruidosas y de mayor varianza; en valle la señal es más estable. Esto explica el **agrupamiento espacial del bajo NDVI** (T1/P2): la calidad del dato depende del emplazamiento.

Evidencia adicional de procesamiento de señales




Figura T3. Espectro FFT y PSD (Welch) de Ener_4: el ruido eleva las altas frecuencias.




Figura T4. Agro_3 (RH): señal noise, referencia clean y filtrada Butterworth.




Figura T2. Costo del Gas (Ener_5): media y varianza móviles (ventana 50).

Generado programáticamente con ReportLab a partir de los módulos de *src/* y las figuras de *figures/*. Reproducible con *py scripts/build_report.py*.